Aritmética de Ponto Flutuante

Prof. Americo Cunha

Universidade do Estado do Rio de Janeiro - UERJ

americo.cunha@uerj.br

www.americocunha.org













Um experimento computacional

$$a = 4/3$$
, $b = a - 1$, $c = 3b$, $e = 1 - c$

Em aritmética exata

$$e = 1 - c = 1 - 3b = 1 - 3(a - 1) = 1 - 3(4/3 - 1) = 0$$

Agora vamos fazer essa conta no GNU Octave:



As operações em ponto flutuante

Sejam fl (x) e fl (y) as representações dos reais x e y em $F(\beta, t, m, M)$, respectivamente. As *operações aritméticas em ponto flutuante*, são definidas por:

$$x \oplus y = \mathtt{fl}(\mathtt{fl}(x) + \mathtt{fl}(y))$$

$$x \ominus y = fl(fl(x) - fl(y))$$

$$x \otimes y = \mathtt{fl}\left(\mathtt{fl}\left(x\right) \times \mathtt{fl}\left(y\right)\right)$$

$$x \oslash y = fl(fl(x)/fl(y))$$

Ao final de cada operação arredonda-se (ou trunca-se).



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y = \operatorname{fl}(\operatorname{fl}(x) + \operatorname{fl}(y))$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y = \text{fl}(\text{fl}(x) + \text{fl}(y))$$

= $\text{fl}(0,9370 \times 10^4 + 0,1272 \times 10^2)$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y = \text{fl}(\text{fl}(x) + \text{fl}(y))$$

$$= \text{fl}(0,9370 \times 10^4 + 0,1272 \times 10^2)$$

$$= \text{fl}((0,9370 + 0,001272) \times 10^4)$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y = \text{fl}(\text{fl}(x) + \text{fl}(y))$$

$$= \text{fl}(0,9370 \times 10^4 + 0,1272 \times 10^2)$$

$$= \text{fl}((0,9370 + 0,001272) \times 10^4)$$

$$= \text{fl}(0,938272 \times 10^4)$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y = \text{fl} (\text{fl}(x) + \text{fl}(y))$$

$$= \text{fl} (0,9370 \times 10^4 + 0,1272 \times 10^2)$$

$$= \text{fl} ((0,9370 + 0,001272) \times 10^4)$$

$$= \text{fl} (0,938272 \times 10^4)$$

$$= 0,9382 \times 10^4 \text{ (truncamento)}$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \oplus y = \text{fl} (\text{fl}(x) + \text{fl}(y))$$

$$= \text{fl} (0,9370 \times 10^4 + 0,1272 \times 10^2)$$

$$= \text{fl} ((0,9370 + 0,001272) \times 10^4)$$

$$= \text{fl} (0,938272 \times 10^4)$$

$$= 0,9382 \times 10^4 (\text{truncamento})$$

$$= 0,9383 \times 10^4 (\text{arredondamento})$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \otimes y$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \otimes y = fl(fl(x) \times fl(y))$$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \otimes y = \text{fl}(\text{fl}(x) \times \text{fl}(y))$$

= $\text{fl}(0,9370 \times 10^4 \times 0,1272 \times 10^2)$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \otimes y = \text{fl}(\text{fl}(x) \times \text{fl}(y))$$

= $\text{fl}(0,9370 \times 10^4 \times 0,1272 \times 10^2)$
= $\text{fl}(0,1191864 \times 10^6)$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \otimes y = \text{fl}(\text{fl}(x) \times \text{fl}(y))$$

= $\text{fl}(0,9370 \times 10^4 \times 0,1272 \times 10^2)$
= $\text{fl}(0,1191864 \times 10^6)$
= $0,1191 \times 10^6 \text{ (truncamento)}$



Um sistema de ponto flutante e dois reais dados:

$$F(10, 4, -1022, 1023)$$
 $x = 9370$ $y = 12, 72$

Representação em ponto flutuante:

$$fl(x) = 0.9370 \times 10^4$$
 $fl(y) = 0.1272 \times 10^2$

→ A representação é exata!

$$x \otimes y = \text{fl}(\text{fl}(x) \times \text{fl}(y))$$

= $\text{fl}(0,9370 \times 10^4 \times 0,1272 \times 10^2)$
= $\text{fl}(0,1191864 \times 10^6)$
= $0,1191 \times 10^6 \text{ (truncamento)}$
= $0,1192 \times 10^6 \text{ (arredondamento)}$





Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$



Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$

Truncamento:

$$x \oplus y = 0,9382 \times 10^4$$

$$x \otimes y = 0,1191 \times 10^6$$



Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$

Truncamento:

$$x \oplus y = 0,9382 \times 10^4$$

$$x \otimes y = 0,1191 \times 10^6$$

$$"x + y = 9382" \neq 9382,72$$

"
$$x + y = 9382$$
" $\neq 9382,72$ " $x \times y = 119100$ " $\neq 119186,4$



Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$

Truncamento:

$$x \oplus y = 0,9382 \times 10^4$$

$$x \otimes y = 0,1191 \times 10^6$$

"
$$x + y = 9382$$
" $\neq 9382,72$

"
$$x + y = 9382$$
" $\neq 9382,72$ " $x \times y = 119100$ " $\neq 119186,4$

Arredondamento:

$$x \oplus y = 0,9383 \times 10^4$$

$$x \otimes y = 0,1192 \times 10^6$$



Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$

Truncamento:

$$x \oplus y = 0,9382 \times 10^4$$

$$x \otimes y = 0,1191 \times 10^6$$

"
$$x + y = 9382$$
" $\neq 9382,72$

"
$$x + y = 9382$$
" $\neq 9382,72$ " $x \times y = 119100$ " $\neq 119186,4$

Arredondamento:

$$x \oplus y = 0,9383 \times 10^4$$

$$x \otimes y = 0,1192 \times 10^6$$

"
$$x + y = 9383$$
" $\neq 9382,72$

"
$$x + y = 9383$$
" $\neq 9382,72$ " $x \times y = 119200$ " $\neq 119186,4$



Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$

Truncamento:

$$x \oplus y = 0,9382 \times 10^4$$

$$x\otimes y=0,1191\times 10^6$$

"
$$x + y = 9382$$
" $\neq 9382,72$

"
$$x + y = 9382$$
" $\neq 9382,72$ " $x \times y = 119100$ " $\neq 119186,4$

Arredondamento:

$$x \oplus y = 0,9383 \times 10^4$$

$$x \otimes y = 0,1192 \times 10^6$$

"
$$x + y = 9383$$
" $\neq 9382,72$ " $x \times y = 119200$ " $\neq 119186,4$

Em geral, operações em ponto flutuante não são exatas.



Aritmética exata:

$$x + y = 9382,72$$

$$x \times y = 119186, 4$$

Truncamento:

$$x \oplus y = 0,9382 \times 10^4$$

$$x \otimes y = 0,1191 \times 10^6$$

"
$$x + y = 9382$$
" $\neq 9382,72$

"
$$x + y = 9382$$
" $\neq 9382,72$ " $x \times y = 119100$ " $\neq 119186,4$

Arredondamento:

$$x \oplus y = 0,9383 \times 10^4$$

$$x \otimes y = 0,1192 \times 10^6$$

"
$$x + y = 9383$$
" $\neq 9382,72$ " $x \times y = 119200$ " $\neq 119186,4$

Em geral, operações em ponto flutuante não são exatas.

Até quando x e y tem representação exata!



Erros nas operações em ponto flutuante

Se fl
$$(x)$$
, fl $(y) \in F(\beta, t, m, M)$ então

$$x \oplus y = (\mathtt{fl}(x) + \mathtt{fl}(y))(1 + \varepsilon_1)$$

$$x\ominus y=(\mathtt{fl}(x)-\mathtt{fl}(y))(1+\varepsilon_2)$$

$$x \otimes y = (\mathtt{fl}(x) \times \mathtt{fl}(y))(1 + \varepsilon_3)$$

$$x \oslash y = (\mathtt{fl}(x) / \mathtt{fl}(y))(1 + \varepsilon_4)$$

onde $|\varepsilon_j| \le \epsilon_M$ (ϵ_M é precisão da máquina).

Essas operações:

- tem erro relativo menor que ϵ_M ;
- não são associativas e nem distributivas.



Desastres envolvendo ponto flutuante

Bolsa de Vancouver

Jan. 1982: ↑ 1000,000 pontos Nov. 1983: ↓ 524,811 pontos Corrigido: ↑ 1098,892 pontos

- Míssil Patriota (25/2/1991)
 28 vítimas fatais e +100 feridos
- Foguete Ariane 5 (4/6/1996)
 U\$ 500M em prejuízo



Patriota ®



Ariane 5*

Detalhes em:

http://shodor.org/succeed-1.0/programs/sspa2002/pages/math_disasters.html

* Figura obtida em https://5g.security/timeline/ariane-5-rocket-explosion/





Para pensar em casa ...

Exercício teórico:

Considere o sistema de ponto flutuante $F(\beta,t,m,M)=F(10,3,-3,4)$, que trunca a parcela que não pode ser incorporada à mantissa. Nesse sistema de ponto flutuante, qual o resultado de 10^3+1-10^3 ?

Exercício teórico:

Sabendo que o sistema de ponto flutuante IEEE 754 de precisão dupla é da forma $F(\beta,t,m,M)=F(2,53,-1022,1023)$, explique porque a maioria dos dispositivos eletrônicos calcula $(1+2^{53})-2^{53}=0$.



Como citar esse material?

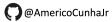
A. Cunha, *Aritmética de Ponto Flutuante*, Universidade do Estado do Rio de Janeiro – UERJ, 2020.











Essas notas de aula podem ser compartilhadas nos termos da licença Creative Commons BY-NC-ND 3.0, com propósitos exclusivamente educacionais.



